.UBAfiuba
FACULTAD DE INGENIERÍA

75.73 Arquitectura de Software

Trabajo Práctico 1

Looney Tunes

Integrantes	Padrón	Email
Andres Zambrano	105500	azambrano@fi.uba.ar
Arian Jarmolinski	94727	ajarmolinski@fi.uba.ar
Mateo Cabrera Rodríguez	108118	mcabrerar@gmail.com
Adrián Romero	103371	adromero@fi.uba.ar

Introducción

El presente informe tiene como objetivo principal exponer una implementación de una API para luego realizar diferentes mediciones que nos permitan evaluar sus atributos de calidad.

Para llevar a cabo el desarrollo de la API, se utilizan las siguientes tecnologías:

- Node.js con Express
- Docker y Docker Compose
- Nginx, como proxy y load balancer
- Redis, como caché
- Artillery, como generador de carga

También se utilizan las siguientes herramientas para realizar mediciones y visualización de las mismas: cAdvisor, StatsD, Graphite y Grafana.

La API desarrollada se compone de cuatro servicios principales que se someterán a distintos escenarios de carga. Estos servicios son:

- Un servicio de ping como healthcheck
- Un servicio de diccionario
- Un servicio de noticias sobre actividad espacial
- Un servicio de citas aleatorias

En el trabajo práctico exploramos distintas optimizaciones, como el uso de Redis como caché, la replicación del servicio, la utilización de Nginx como load balancer y la implementación de ate limiting para el consumo de la API.

El informe incluirá también capturas de pantalla del dashboard de métricas para cada caso analizado, así como una vista Components & Connectors que represente la arquitectura del sistema para los distintos casos estudiados.

Diagramas

A continuación mostramos los diagramas components and connectors para las situaciones que evaluamos:

Un nodo

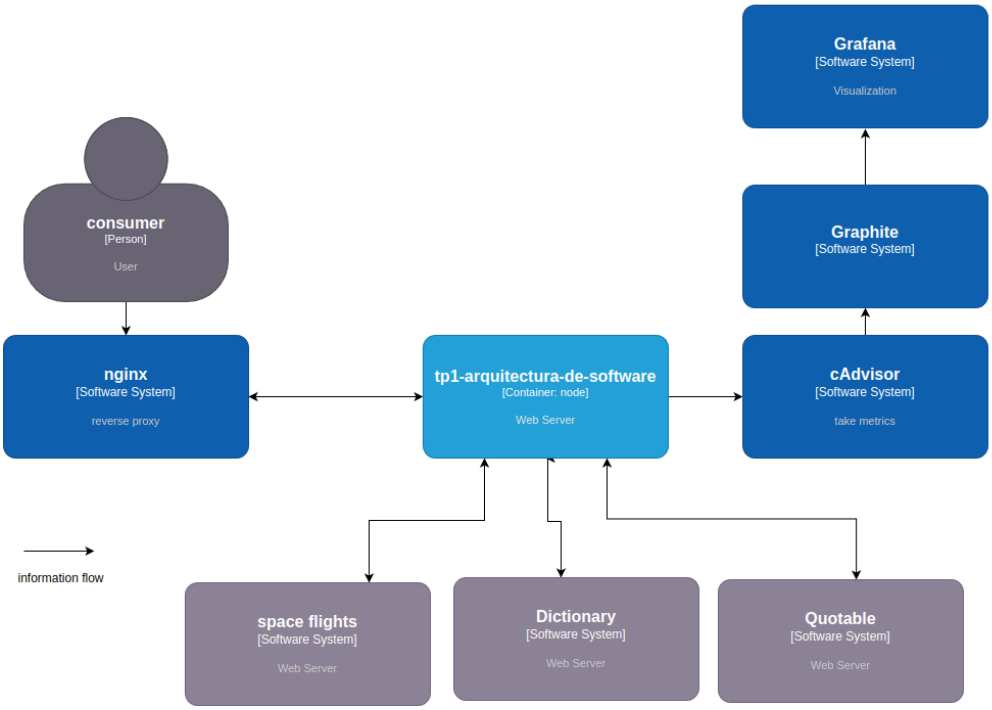

Un nodo y caché

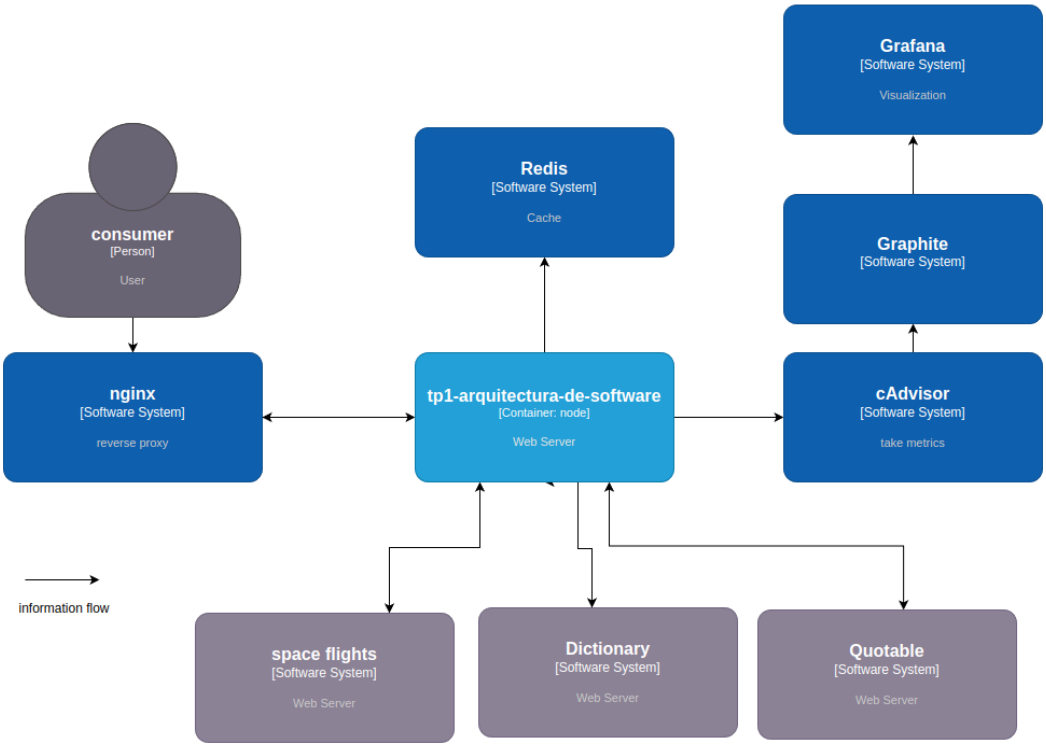

Tres nodos y load balancing

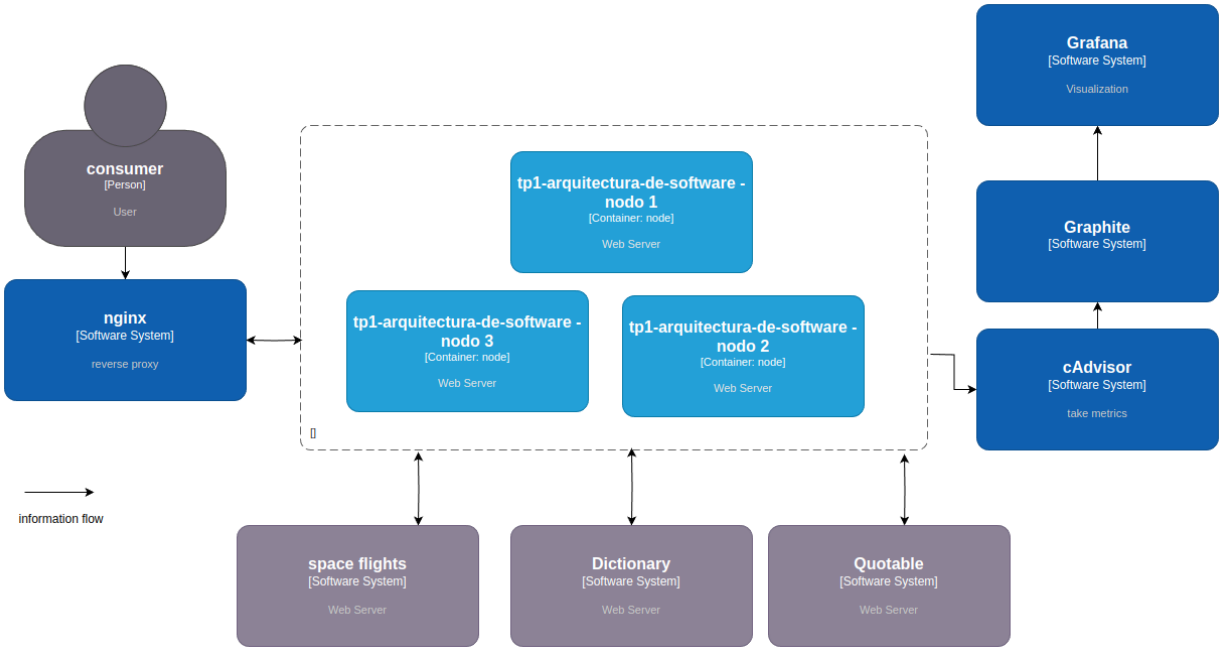

Pruebas realizadas

A lo largo del trabajo práctico, vamos a exponer los distintos endpoints que conforman nuestra API a diferentes intensidades de requests enviados para evaluar y comparar su performance, teniendo en cuenta las siguientes métricas:

- Cantidad de requests respondidos por segundo
- Estado HTTP de los requests respondidos
- Tiempo de respuesta percibido por el usuario
- Tiempo de respuesta percibido por el servidor
- Uso de CPU & Memoria

Ping

Este endpoint (/ping) simplemente devuelve un string con el valor ‘pong’. Debido a la simpleza de este endpoint, esperamos que el procesamiento de memoria y el uso de CPU sea bajo. También el tiempo de respuesta percibido por el usuario y por el servidor debería resultar bajo.

El caso inicial bajo el cual evaluaremos este endpoint estará conformado por las siguientes fases:

1. **Calentamiento:** por una duración de 30 segundos se envían requests a una tasa de 5 requests por segundo.
2. **Ramp up:** por una duración de 30 segundos se incrementa gradualmente la tasa de envíos a 30 requests por segundo.

3. **Plain:** por una duración de 90 segundos se envían requests a una tasa de 30 requests por segundo.
4. **End**: por una duración de 15 segundos se envían requests a una tasa de 1 request por segundo.

Escenarios creados

En este gráfico podemos ver en el eje Y la cantidad de requests recibidos por el servidor en los últimos 10 segundos, por este motivo vemos este eje escalado en un factor de 10 respecto de la cantidad requests enviados por segundo.

Podemos apreciar claramente las distintas fases del escenario propuesto: la fase de calentamiento donde se inician los requests a tasa de 5 por segundo, seguido del ramp gradual en el que se eleva la cantidad de requests por segundo a 30 y luego una meseta en la etapa plain, finalmente la tasa cae a 1 request por segundo en la última fase.

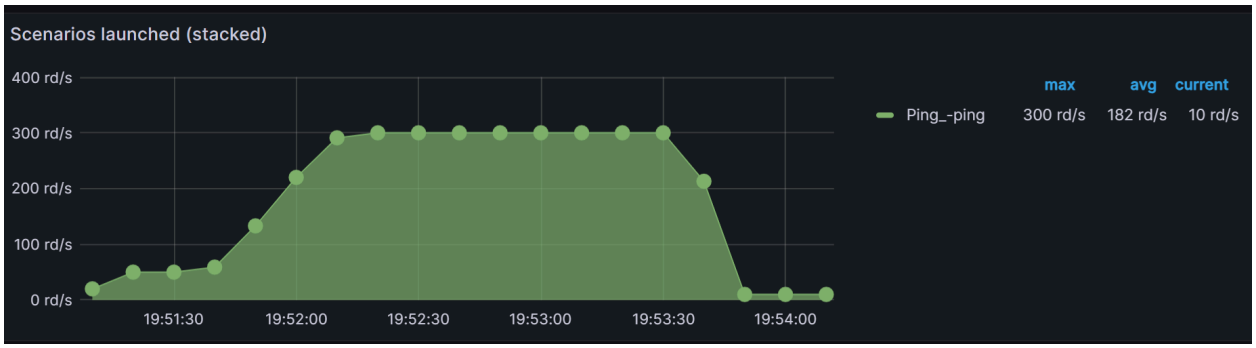

Estado de los requests

Respecto del estado de los requests, vemos que todos los requests fueron completados correctamente, con el código de estado HTTP 200.

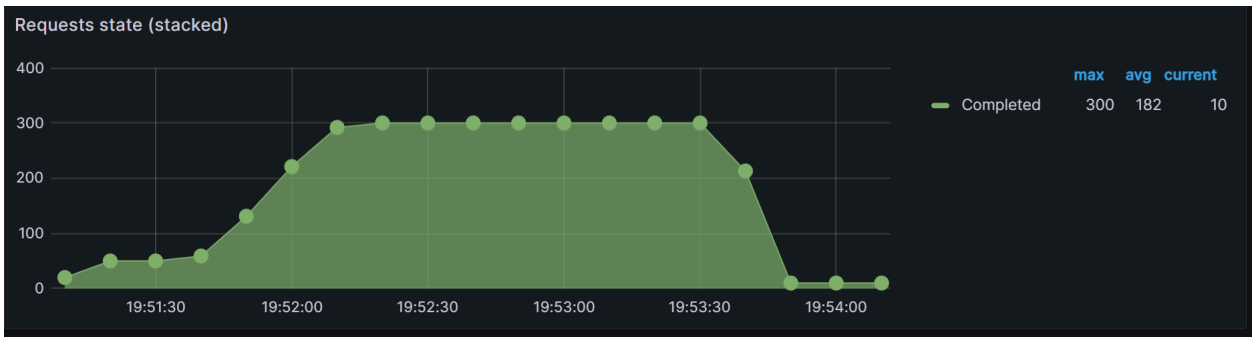

Tiempo de respuesta percibido

Esperamos que el tiempo de respuesta percibido por el usuario sea bajo, pues este endpoint no realiza procesamiento, ni debe esperar la respuesta de una api remota, como sí sucederá en los siguientes endpoints.

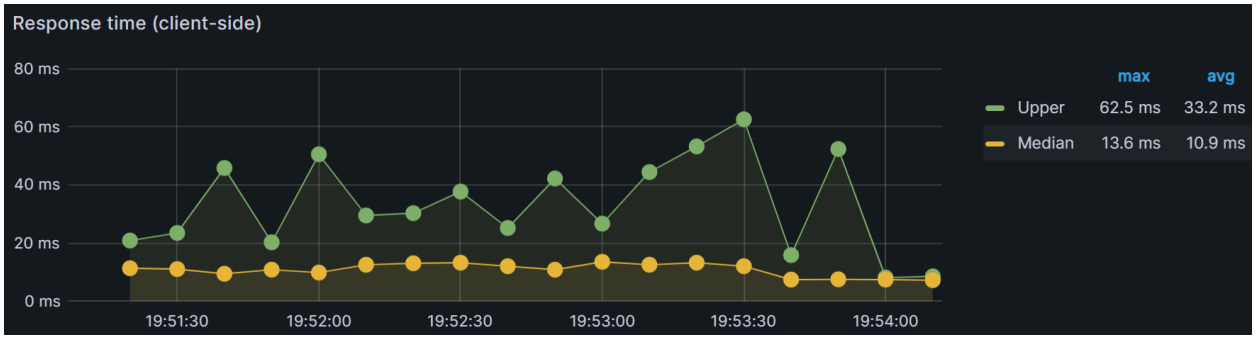

Efectivamente, el tiempo de respuesta que observamos es muy bajo, con una mediana máxima de 13.6 ms.

Uso de memoria y CPU

Tal como esperábamos el uso de memoria y de CPU para este endpoint es muy bajo. Además, el uso de CPU parece seguir la forma que vimos en los primeros gráficos, lo que indica que, lógicamente a mayor cantidad de requests recibidos por el servidor, el uso de CPU fue mayor. Por otro lado, este endpoint no hace uso de memoria, por lo cual se mantuvo bajo.

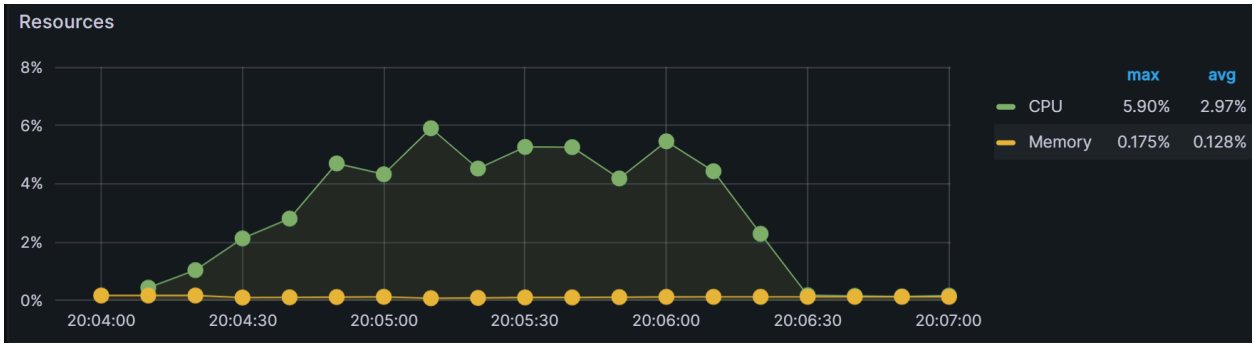

Ping - Rate limiting

Ahora vamos a testear el comportamiento del endpoint bajo el caso anterior pero incorporando un rate limiter que permita como tasa máxima 20 requests por segundo.

Estado de los requests

Respecto del estado de los requests, lo que esperamos ver es que hayan requests rechazados, debido a que en la etapa plain se alcanza una tasa de 30 requests por segundo. Podemos ver, como esperábamos, que un tercio de los requests son rechazados en la etapa plain.

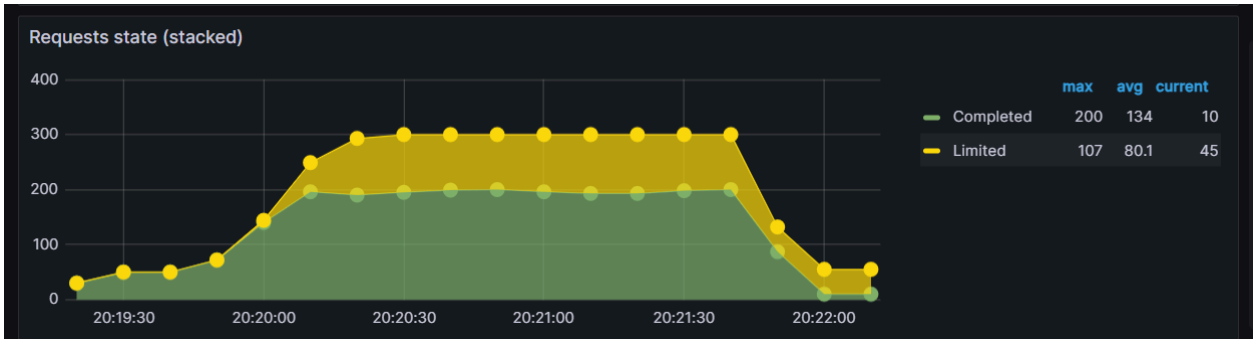

Uso de memoria y CPU

Como esperábamos, el uso del CPU es menor en este caso. El máximo uso es de 4.25%, cuando sin rate limiting era de 6%. Esto es posible que se deba a que la cantidad de requests procesados es menor debido a que se rechazan reque

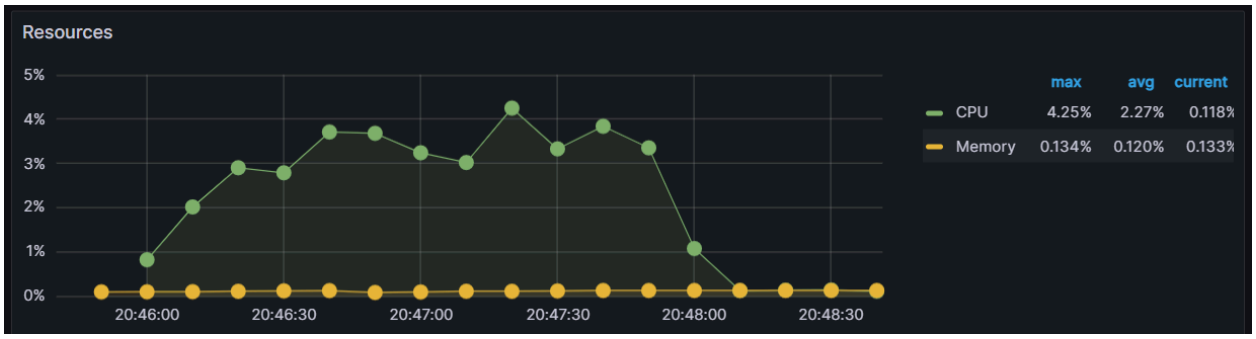

sts.

Spaceflight News

En el endpoint (/spaceflight_news), devolveremos solo los títulos de las 5 últimas noticias sobre actividad espacial, obtenidas desde la Spaceflight News API.

En este endpoint esperamos ver un mayor tiempo de respuesta percibido por el usuario y por el servidor, pues este endpoint consulta una API externa, por lo que se debe esperar a la respuesta de esta API externa antes de continuar con el procesamiento y realizar una

devolución al usuario. Además también esperamos ver un mayor uso de CPU y memoria debido a que se realiza una manipulación y formateo de los datos recibidos de la API externa.

Corriendo el caso base para este endpoint los gráficos de Escenarios Creados & Estado de los requests son iguales a los primeros. Por este motivo, presentamos los resultados para el tiempo de respuesta percibido y el uso de memoria:

Tiempo de respuesta percibido

Si comparamos el tiempo de respuesta percibido por el cliente con el de /ping, vemos que es aproximadamente 100 veces mayor, esto tiene sentido pues este endpoint requiere de mayor procesamiento.

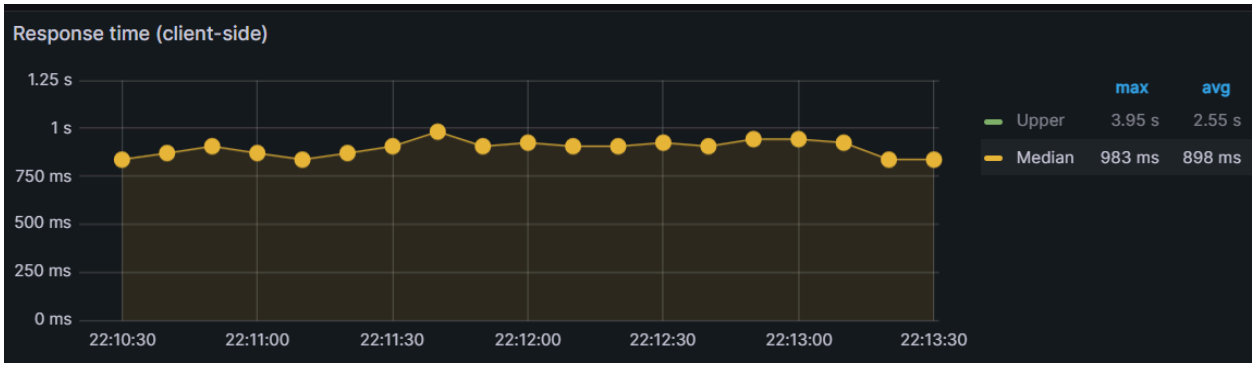

Además, si comparamos el tiempo de respuesta medido desde el lado del servidor con el tiempo de respuesta de la api remota, vemos que son muy similares. Esto es de esperarse, la mayor parte del tiempo de procesamiento está en esperar la respuesta de la api remota.

También podemos observar que el tiempo de respuesta percibido por el cliente y por el servidor no tienen mucha diferencia (aproximadamente 800ms, aunque el percibido por el servidor es ligeramente menor), esto parecería indicar que el tiempo en el que viaja la información desde el servidor al cliente es muy reducido. Posiblemente debido a que tanto cliente como servidor están en el mismo host local.

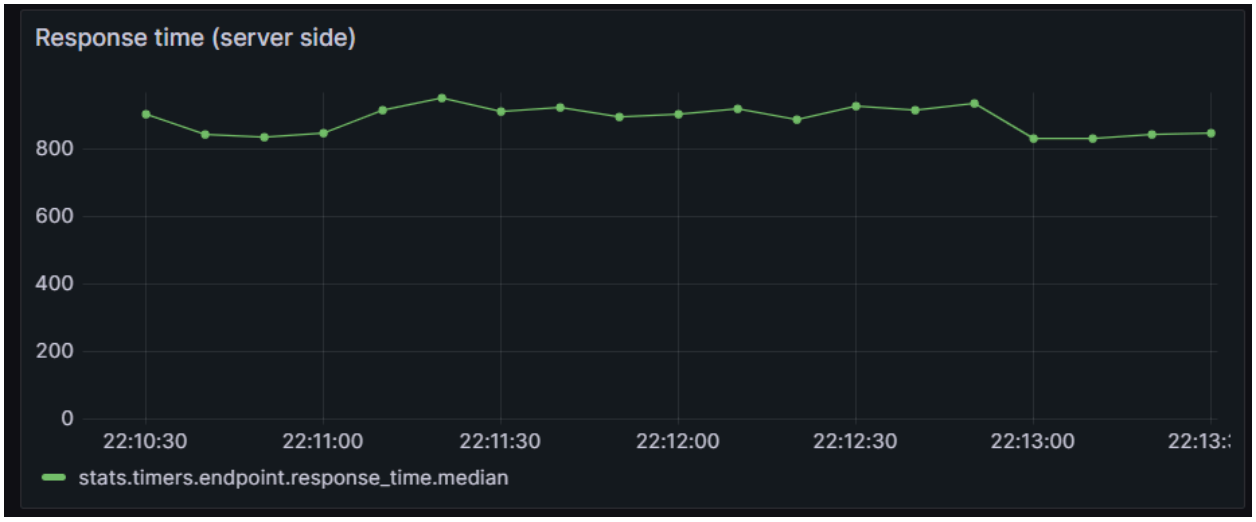

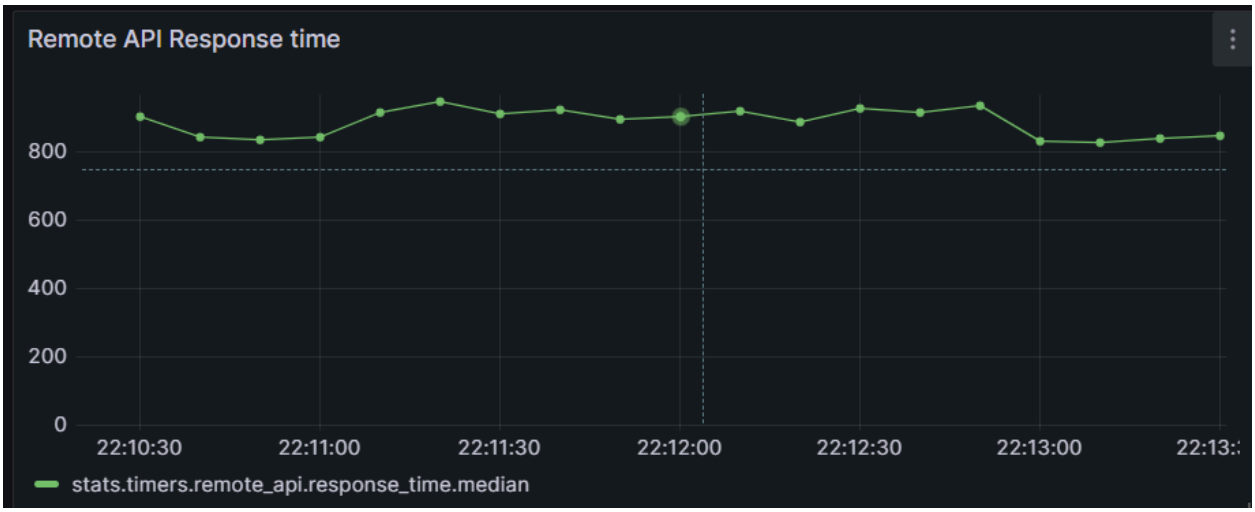

Uso de memoria y CPU

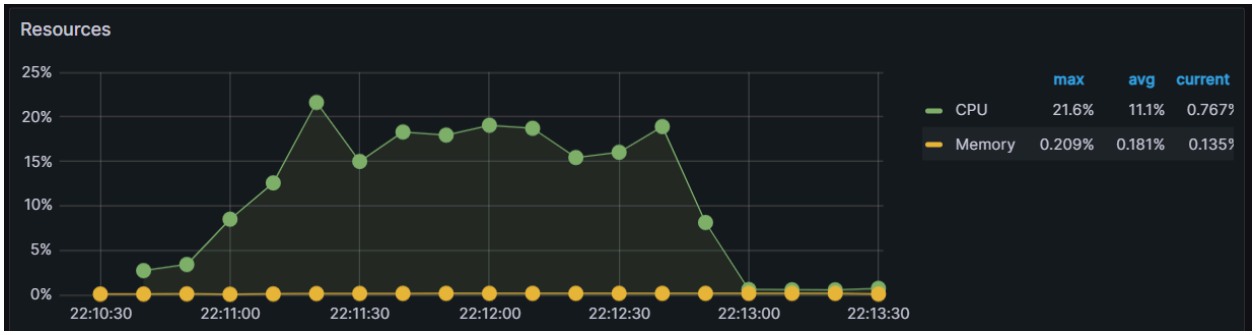

Claramente, comparando con el caso de /ping, el máximo uso de memoria es muchísimo mayor (21% vs 6%) lo cual es esperable debido a que este endpoint realiza un formateo de los datos provenientes de la API remota antes de responderle al cliente.

Spaceflight News - Cache

Debido a que este endpoint nos trae las últimas noticias sobre actividad espacial y no esperamos que estas sean actualizadas con gran frecuencia, decidimos realizar un cacheado de los datos.

Esperamos que esto disminuya el tiempo de respuesta percibido por el usuario, así como también el tiempo de respuesta del servidor, al no tener que ir a buscar los datos a la API remota y procesarlos, sino que los datos estarán cacheados en Redis.
Usar la caché también debería reducir el uso de CPU, ya que los datos de respuesta no serán procesados por el servidor, sino devueltos tal cual están cacheados.

Para estas pruebas, decidimos cachear la respuesta de la API de manera lazy, es decir, que recién cuando el cliente accede a nuestro endpoint, existe la posibilidad de que traigamos los datos de la API remota si no están ya en la caché. Para este endpoint en particular, tiene sentido también realizar un cacheado active, para ya tener la información disponible cuando el cliente acceda a nuestro endpoint.

Sobre el tiempo de vida de los datos cacheados decidimos ponerles 5 segundos, pues no encontramos documentación en la API de Spaceflight News acerca de con qué frecuencia se actualizan las últimas noticias.

También, notamos que no sería necesario realizar un vaciado de la caché cuando un cliente sea respondido con el objeto almacenado en la caché. Esto es porque sería correcto que dos clientes distintos sean respondidos con el mismo objeto almacenado en la caché, dado que ambos deberían recibir las mismas últimas noticias.

Tiempo de respuesta percibido

Claramente el tiempo de respuesta de la API remota es el mismo que en el caso de no usar caché (aproximadamente 800ms), pues la API externa sigue tardando lo mismo en respondernos cada vez que le solicitamos los datos. Lo que cambia es la frecuencia con la que le solicitamos los datos a esta API.

Por otro lado, los tiempos de respuesta percibidos tanto por cliente como por el servidor disminuyen drásticamente, pues para un gran porcentaje de las solicitudes, ya no nos quedamos esperando la respuesta de la API remota, sino que respondemos con el contenido de la caché. Esto se puede ver en los siguientes gráficos:

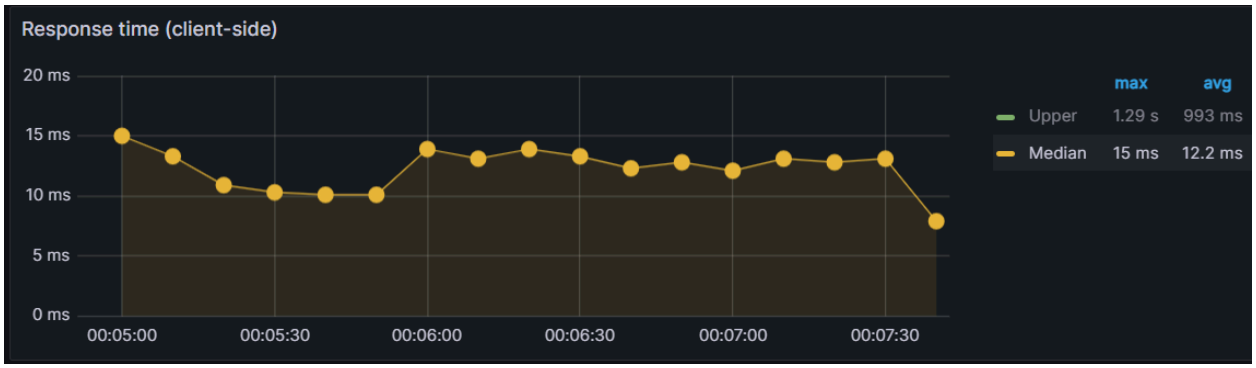

Uso de memoria y CPU

Los recursos utilizados también se redujeron, como esperábamos,pues el procesamiento es menor al utilizar los datos de la caché al no tener que procesar los datos provenientes de la API remota.

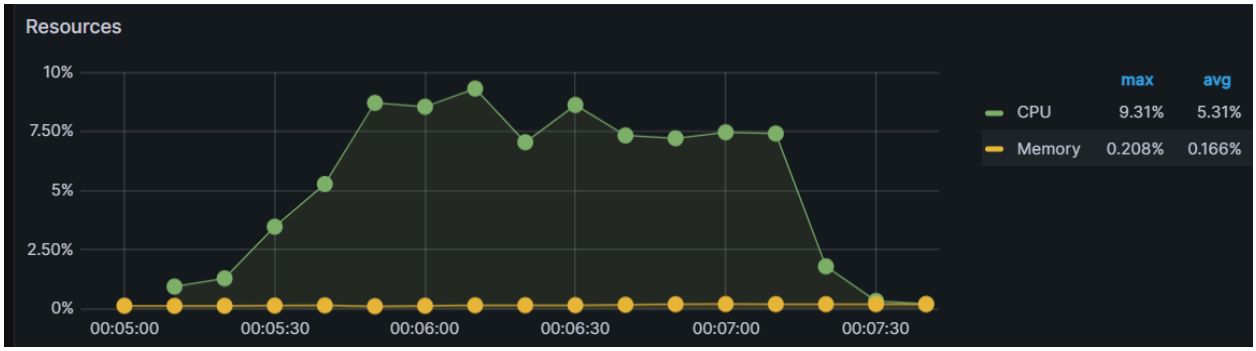

Dictionary

En el endpoint: /dictionary?word=<word>, devolveremos la fonética y los significados de palabras en inglés, consultando a la Free Dictionary API. En términos de intensidad de procesamiento es similar al endpoint spaceflight news.

Además para realizar las pruebas sobre este endpoint utilizaremos un archivo csv denominado words.csv en el cual incluimos un listado de palabras en inglés que se utilizan como parametro del endpoint al armar las requests con artillery en el archivo dictionary.yaml

Estado de los requests

Al realizar esta prueba y revisar el estado de las responses pudimos ver que muchos de los requests que se realizaron fallaron con status code 429 debido a que Free Dictionary API nos retornó '**TOO_MANY_REQUESTS**':

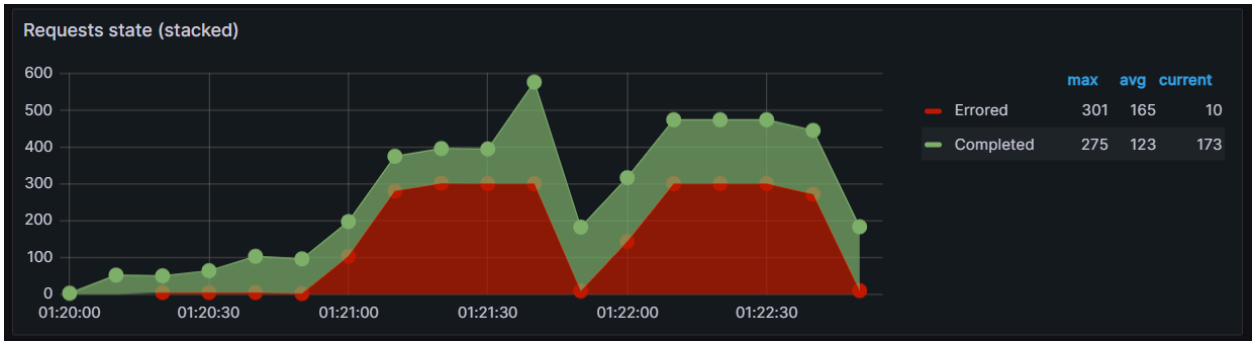

Estado de los requests - Ramp

Dado que pudimos ver requests rechazados a una tasa de 5 requests por segundo (tasa que utilizamos como warm-up), proponemos el siguiente escenario con la esperanza de que nos permita ver cuál es el rate limit:

- Cada 20 segundos incrementar la tasa en 1 requests por segundo, empezando en 1 y terminando en 10.

Realizando esta prueba pudimos ver que los errores recibidos se disparan cuando la cantidad de requests enviados por segundo alcanza el valor de 5.

Tiempo de respuesta percibido

Considerado el caso inicial, podemos ver que nuevamente la mayor parte del tiempo de la respuesta del servidor se le dedica a esperar la respuesta de la API remota. También pudimos observar que a partir de que empezamos a recibir requests fallidos, dejamos de recibir estas métricas que incorporamos con hot-shots.

Por otro lado vemos también que el tiempo de respuesta de esta API remota es considerablemente menor que el de Spaceflights News (500ms contra 900ms).

Cache

Cómo táctica a probar, decidimos usar una caché de Redis para almacenar las palabras que los usuarios solicitan, así como también sus *phonetics* y *meanings* correspondientes. Esto lo hacemos porque consideramos que es probable que si hay muchos usuarios, estos consulten la misma definición en un dado lapso de tiempo. La táctica propuesta es almacenar cada palabra que es consultada por 10 segundos, pues es un tiempo en el que nos parece probable que dos (o más) usuarios consulten por la misma palabra.

Adicionalmente, para realizar esta prueba, utilizamos otro archivo csv denominado *words-with-repetitions.csv*. Este archivo contiene aproximadamente 5000 palabras, que fueron elegidas a partir de un subconjunto de 30 palabras diferentes. Esto logrará simular que varios

usuarios busquen la misma palabra en intervalos reducidos de tiempo.

En los response time podemos ver una particularidad y es que hay constantes subidas y bajadas en el *upper*, mientras que la mediana se mantiene relativamente constante y baja.

Debido a que parte de los requests se responden desde la caché se reduce la probabilidad de ir a buscar datos a la API remota, esto puede hacer que la API remota esté respondiendo más rápido. Además, en los momentos en donde nuestra caché está más vacía (o se consulta por datos que no estan en la caché)I, se realizan más consultas a la API remota y se aumenta su carga y por lo tanto también aumenta su response time máximo..

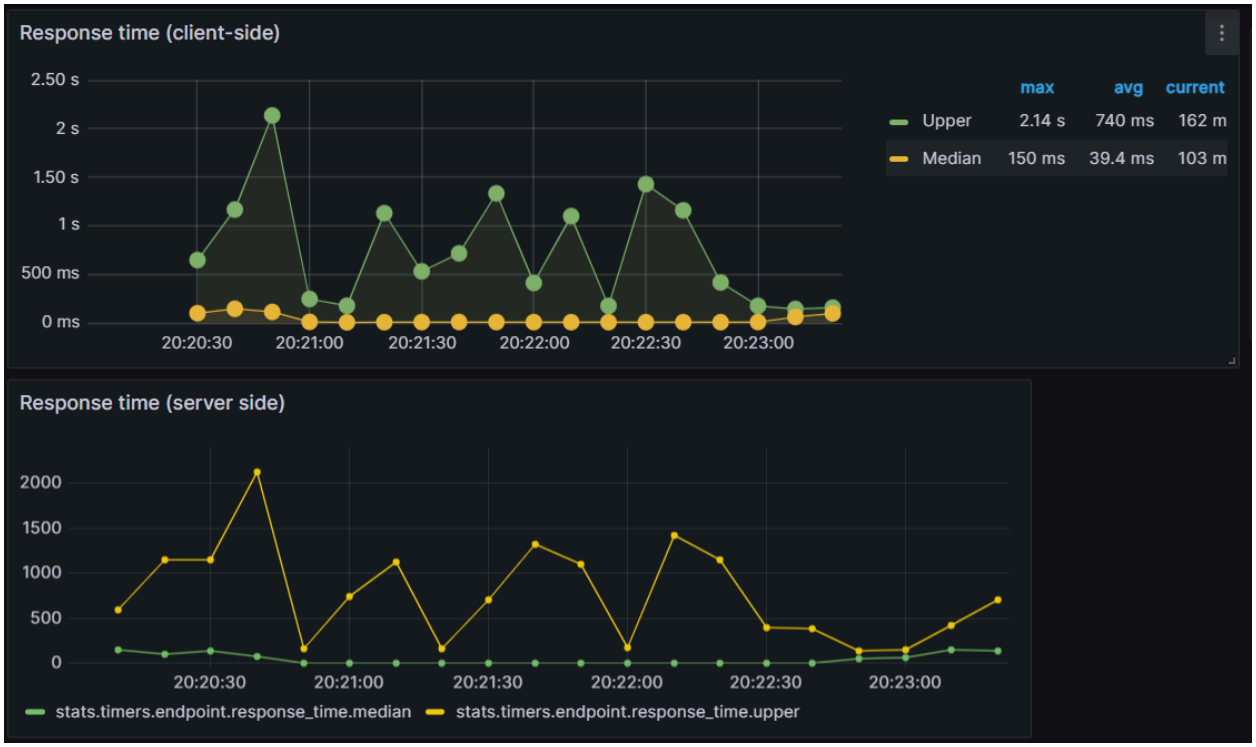

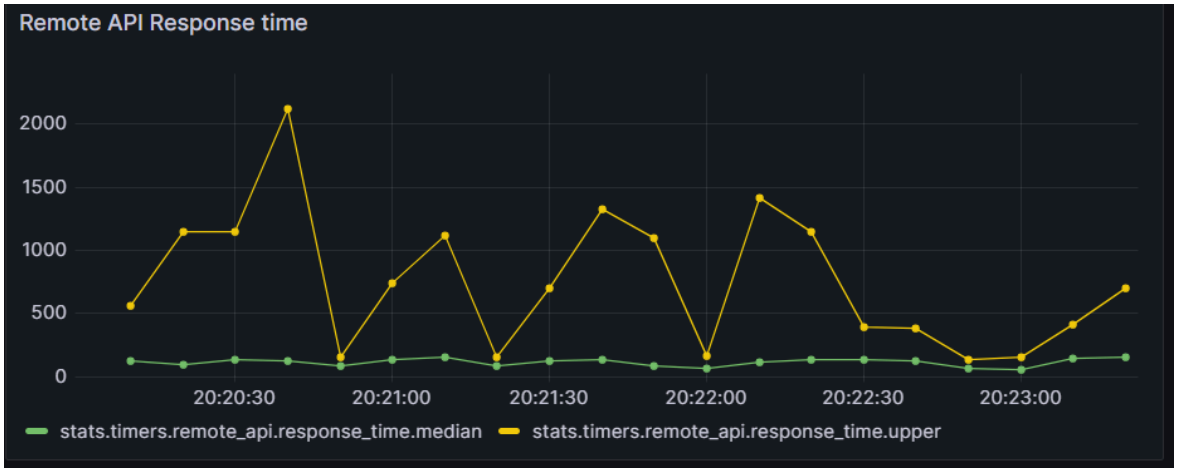

Respecto del estado de la respuesta, utilizando caché logramos reducir la carga de la API remota al enviarle menos requests y esto trajo aparejado una reducción significativa en los errores recibido, debido a que el rate limiter de la api remota nos limitó menos requests.

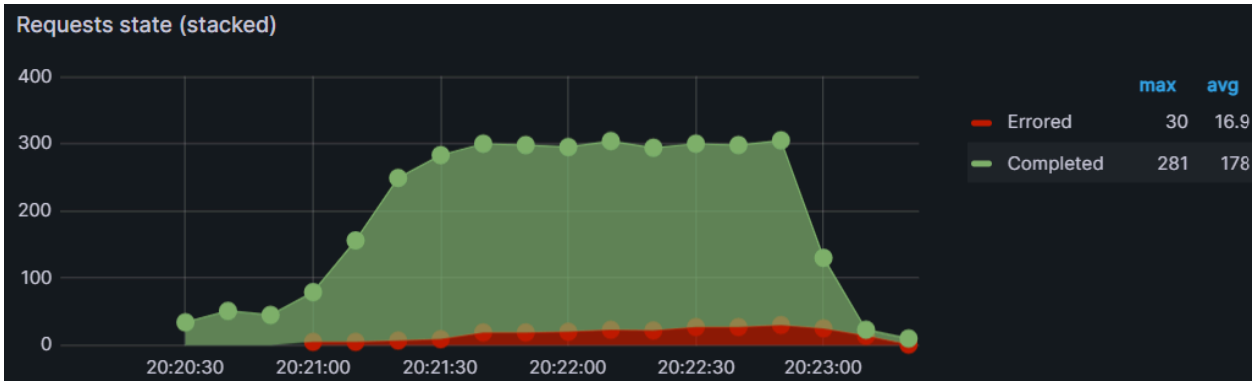

Quote

En el endpoint /quote devolveremos 1 cita famosa al azar, junto con su autor por cada invocación, tomada de Quotable. Debe evitarse entregar la misma cita cada vez (salvo que la repita la API remota).
Para este caso tampoco utilizaremos caché para almacenar los datos del endpoint externo. Al ser frases al azar, el cache no mejorará los tiempos de respuesta.

Estado de los requests

Similar a los resultados obtenidos con la API de dictionary, observamos muchas requests que fallaron al superar cierto umbral.

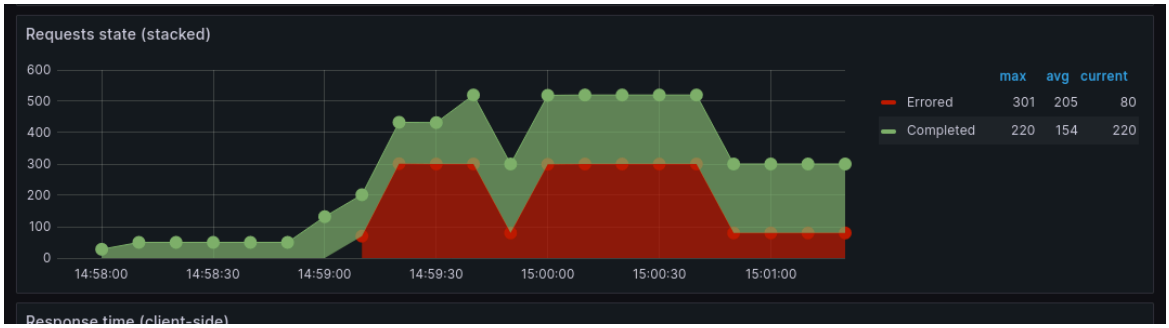

Estado de los requests - Ramp

Debido a que los errores los empezamos a observar en la fase de Ramp-up. Vamos a utilizar una táctica similar a lo que hicimos con Dictionary. Para conocer el rate-limit, proponemos el siguiente escenario:

- Cada 20 segundos incrementar la tasa en 1 requests por segundo, empezando en 1 y terminando en 14.

Realizando esta prueba pudimos ver que los errores recibidos se disparan cuando la cantidad de requests enviados por segundo se acerca a 5 o 6.

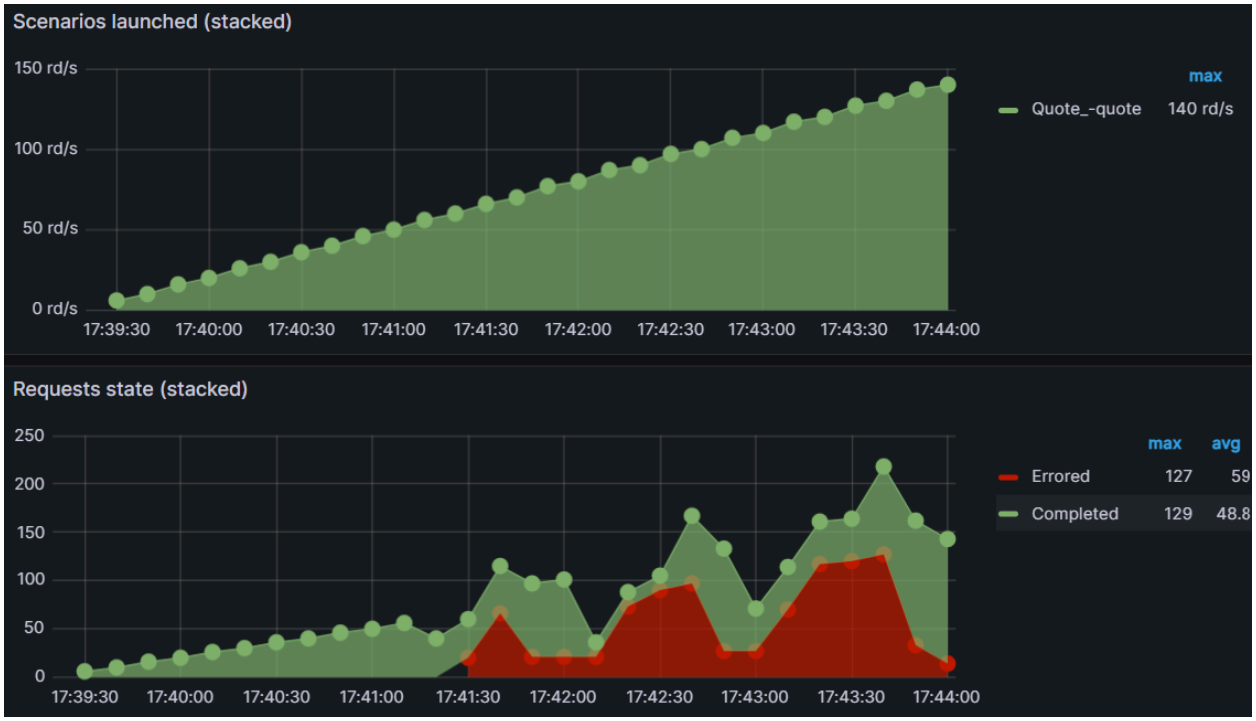

Tiempo de respuesta percibido

Nuevamente, por la lógica que sigue esta API, la mayor parte del tiempo de la respuesta del servidor, pasa esperando una respuesta de la API externa.
Los tiempos de respuesta de este endpoint son muy similares a los tiempos de respuesta de el de Dictionary, al igual que los tiempos de respuesta de sus respectivas APIS remotas.

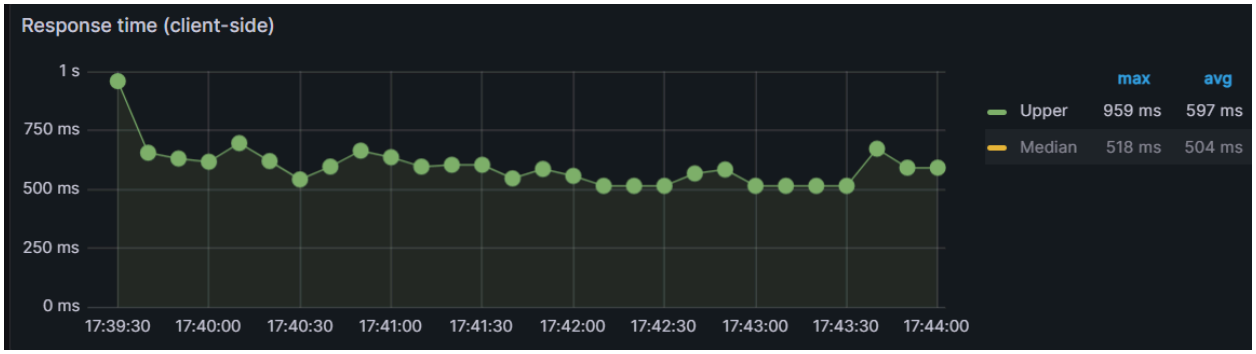
Response time (client-side)
1 s
750 ms
500 ms
250 ms
0 ms
17:39:30
17:40:00
17:40:30
17:41:00
17:41:30
17:42:00
17:42:30
17:43:00
17:43:30
17:44:00
max
avg
Upper
959 ms
597 ms
Median
518 ms
504 ms


Remote API Response time
500
400
300
200
100
0
17:39:30
17:40:00
17:40:30
17:41:00
17:41:30
17:42:00
17:42:30
17:43:00
17:43:30
stats.timers.remote_api.response_time.median

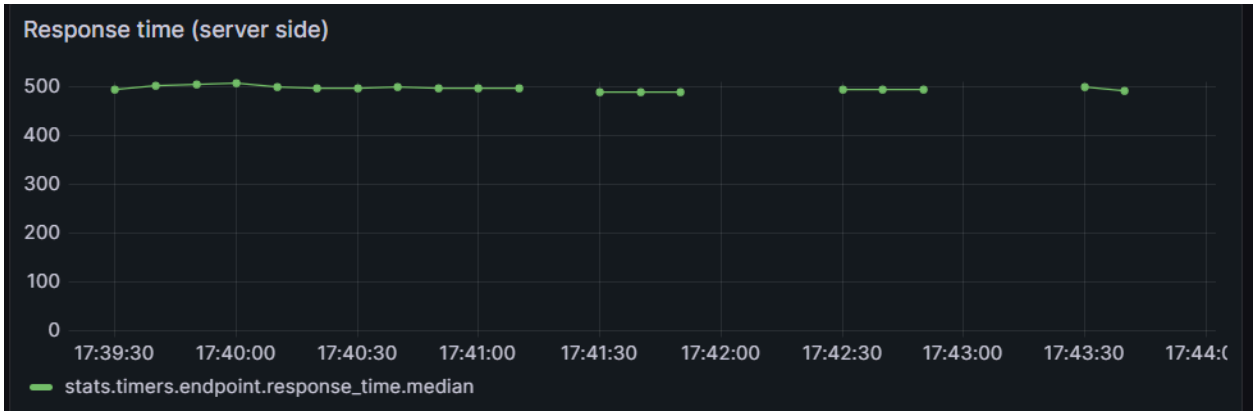
Response time (server side)
500
400
300
200
100
0
17:39:30
17:40:00
17:40:30
17:41:00
17:41:30
17:42:00
17:42:30
17:43:00
17:43:30
stats.timers.endpoint.response_time.median

Cache

Propusimos luego utilizar la caché de Redis para almacenar datos de la API remota. El funcionamiento es el siguiente: cuando un usuario solicita un quote a nuestra API, esta busca en la cache si hay una quote disponible, si no la hay, se busca en la API remota 50 quotes y se almacenan en la cache. Escogimos traer 50 pues es el máximo de quotes diferentes que se permite traer, según la documentación.

Cómo observación, esta propuesta suponemos que introducirá mejoras en la performance, pero por otro lado sacrificará en términos de funcionalidad, pues se deja de asegurar que cada quote respondido sea diferente. Esto sucede porque si llegan varios requests a nuestra API en un periodo corto de tiempo, estos pueden llegar a leer el mismo elemento en la caché.

Podemos ver que la mediana del tiempo de respuesta percibido, tanto por el servidor como el cliente, se reduce significativamente, pues la mayor parte de las respuestas están proviniendo de datos cacheados, y en estos casos no hay que esperar la respuesta de la API remota. Sin embargo vemos que el máximo tiempo de respuesta se mantiene, lo cual es coherente siendo que un solo request a la api remota lleva a esto.

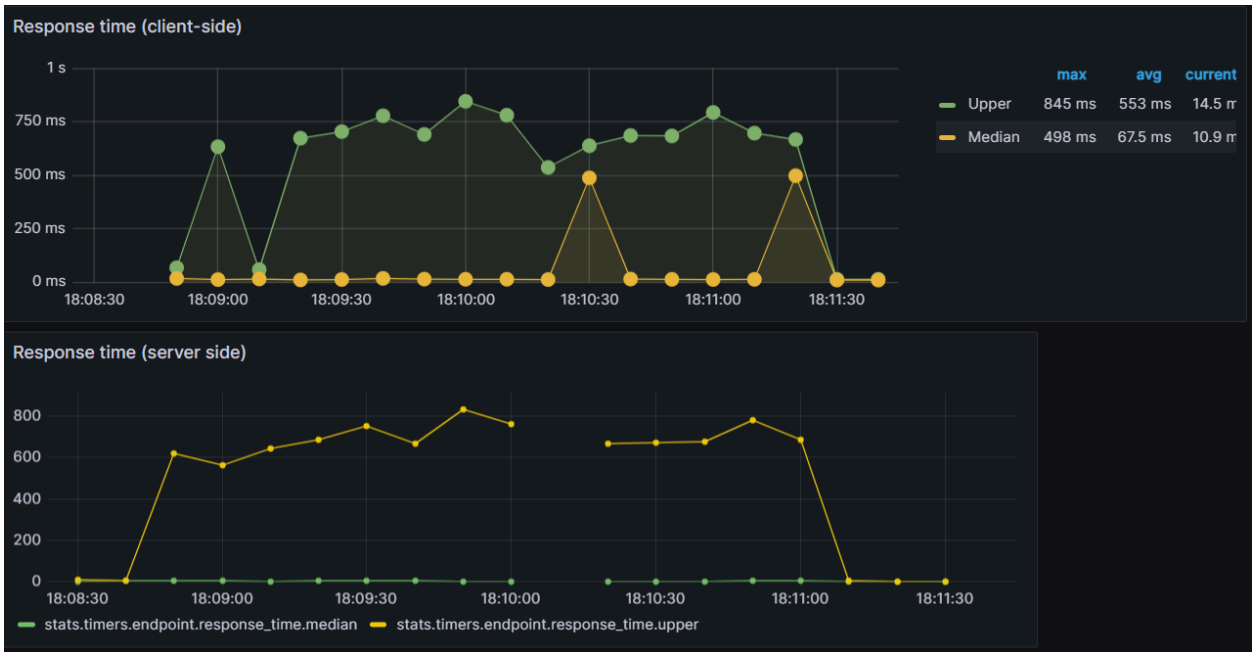

También vemos que los fallos por Too Many Requests ocurren más tarde que en el caso sin cache. Esto se debe a que, al traer datos cacheados, el rate limiting de la API remota no nos limita tanto porque le estamos haciendo una cantidad menor de requests a la API remota. Esto hace que cueste más llegar a hacerle a la API remota una cantidad de requests antes de que nos empiece a limitar.

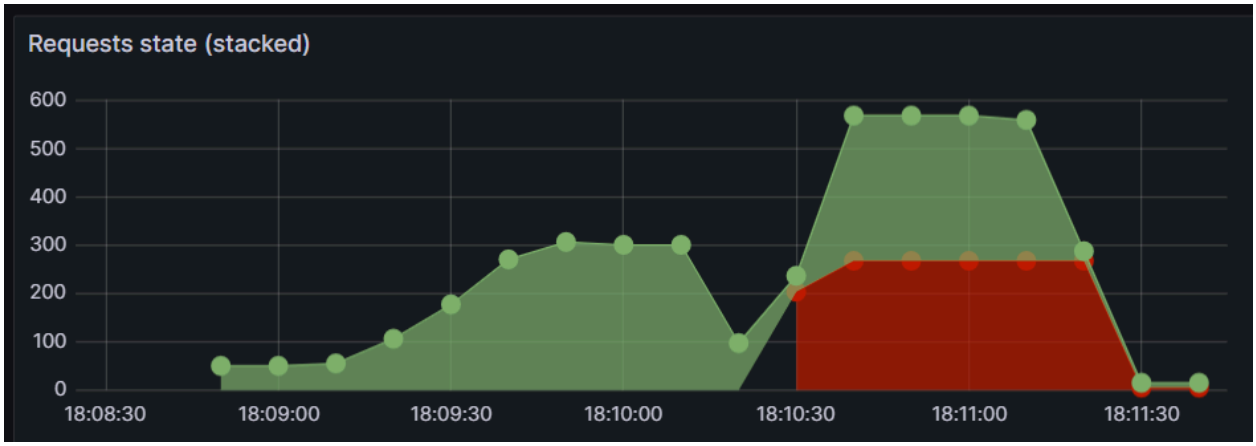

Finalmente el tiempo de respuesta de la API remota no varía respecto de la versión sin caché, como es esperable.

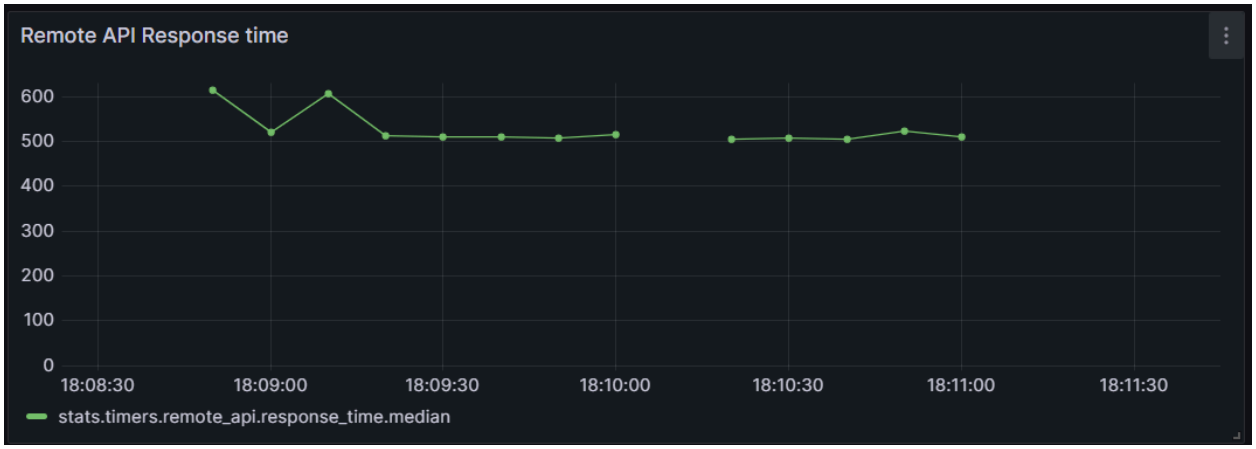

Prueba con tres réplicas

Para la siguiente prueba decidimos comparar el uso de recursos utilizando el endpoint /spaceflight_news sin caché, pero esta vez, distribuyendo la carga equitativamente en 3 nodos. Esto lo conseguimos utilizando nginx como loadbalancer. Esperamos que el uso de los recursos sea menor en cada nodo que al estar procesando todas las requests en un solo nodo.

Los resultados que obtuvimos fueron los siguientes:

Uso de memoria y CPU

Nodo 1:

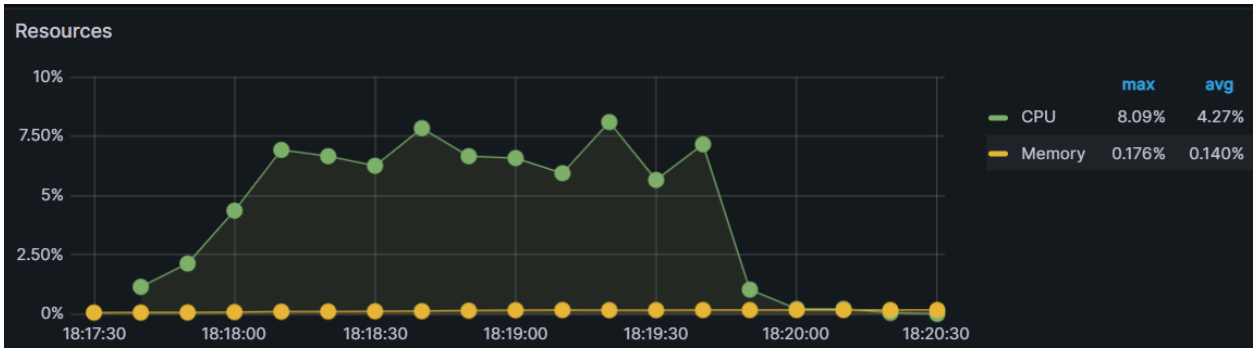

Nodo 2:

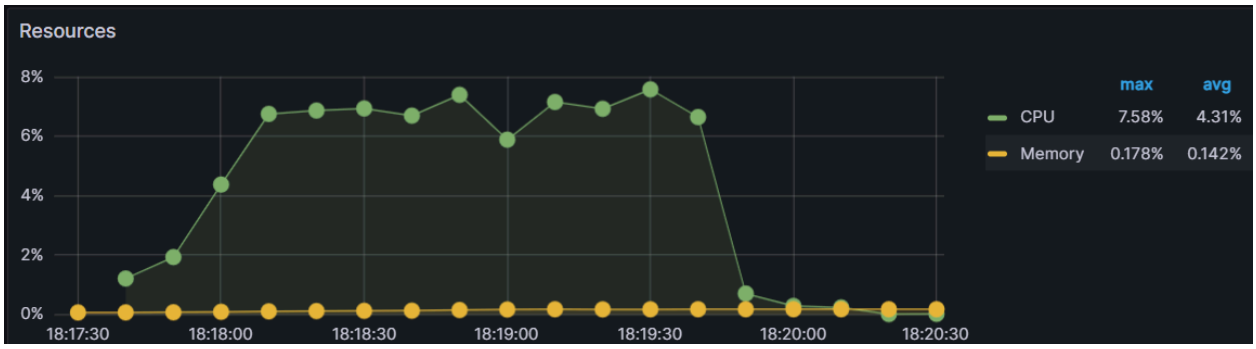

Nodo 3:

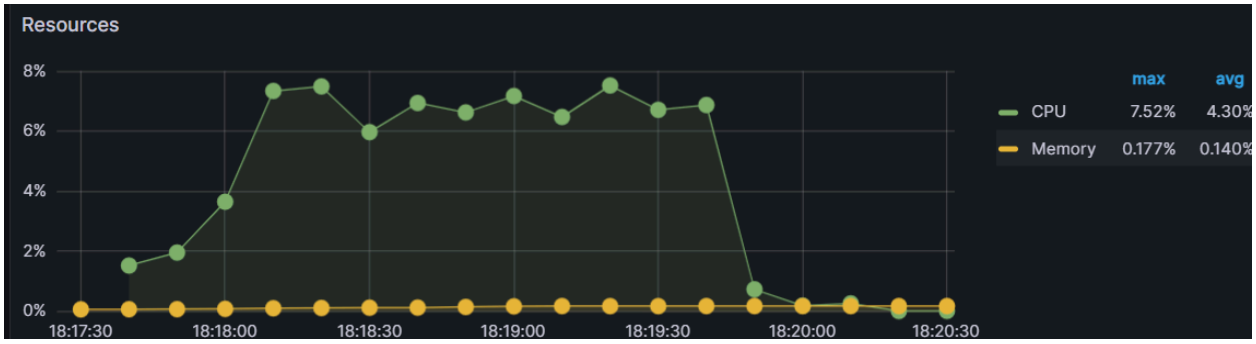

Nginx:

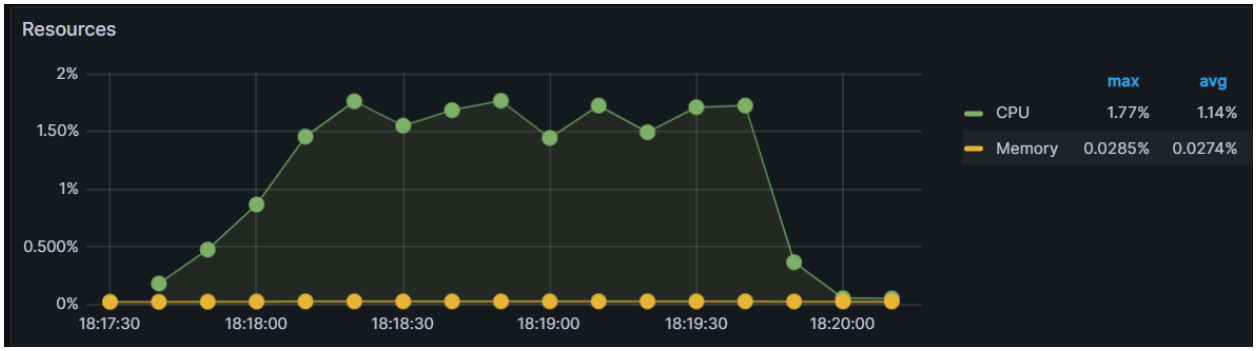

Podemos ver que el % de uso de CPU en los tres nodos es muy similar, esto indica que efectivamente el load balancer realiza un round robin en el cual todos los nodos tienen el mismo peso y por lo tanto la carga se disminuye de manera equitativa.

Además comparando con el caso de 1 solo nodo, el uso de CPU de estos 3 nodos fue menor (7,5% vs 21%) es decir casi un tercio.

Tiempo de respuesta percibido

El tiempo de respuesta percibido por el usuario parece disminuir levemente comparando con la contraparte de 1 solo nodo (980ms vs 925ms)

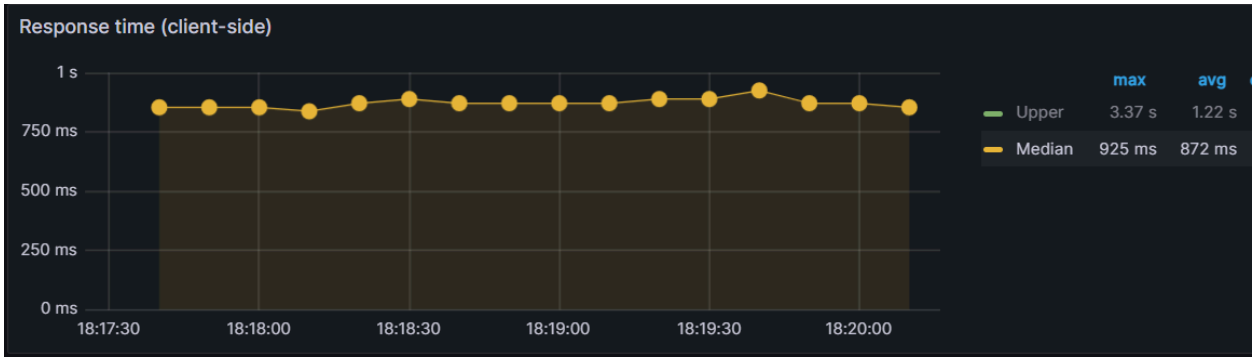

Conclusiones

Durante el desarrollo de este trabajo práctico, hemos tenido la oportunidad de utilizar una gran variedad de herramientas que permiten la observabilidad y medición de nuestros componentes, pudiendo comparar cómo responde un servidor ante diferentes situaciones de carga. A continuación, presentamos un análisis detallado del impacto de diversas tácticas de mejora.

Rate Limiting:
Implementamos un rate limiter en nuestra API para controlar la cantidad de solicitudes que los usuarios podían hacer en un determinado período. Esta táctica mejoró la **fiabilidad** del sistema al prevenir rechazos masivos de solicitudes, aunque introdujo una restricción en la experiencia del usuario.

Caché:
Utilizamos Redis como sistema de caché para almacenar respuestas de las APIs externas. Esto redujo significativamente el tiempo de respuesta para solicitudes repetitivas y disminuyó la carga en los servicios externos. Este enfoque mejoró la **eficiencia** y la **velocidad** del sistema. Sin embargo, la actualidad de los datos se vio comprometida .

También la caché nos sirvió para mitigar las limitaciones de los rate limiter de las APIs externa y mantener una experiencia de usuario consistente. Pre-cargamos datos con respuestas que se pueden devolver inmediatamente a los usuarios y esto mejoró la capacidad de respuesta del sistema y la experiencia del usuario, especialmente durante momentos de gran carga.

Replicación y Balanceo de Carga:
Implementamos una arquitectura con tres nodos utilizando Nginx como balanceador de carga. Con esta configuración distribuímos la carga equitativamente entre los nodos, resultando en un menor uso de CPU por nodo comparado con una configuración de nodo único (7.5% vs. 21%). Además, el tiempo de respuesta percibido por el usuario disminuyó ligeramente (925ms comparado con 980ms en una configuración de nodo único). Estas mejoras impactaron positivamente la **escalabilidad**, la **disponibilidad**, y la tolerancia a fallos del sistema.